

## **Dokumen Project Plan**

### **Pijak in collaboration with IBM Skillsbuild**

**ID Tim Capstone Project:** PJK-GM090

**Tema Capstone** : AI For Productivity and Automation

**Nama Proyek/Product** : AI SHIELD (Smart Handling of Integrity in Ethical Live Dialogue)

**List Anggota** :

1. APC008D6Y0478 - Ahsani Fadhli Ilahi - **[Aktif]**
2. APC189D6X0273 - Salsabila Januaryaneda - **[Aktif]**
3. APC189D6X0275 - Nayla Faiza Gusvie Abdullah - **[Aktif]**
4. APC189D6X0274 - Ammi Sumiyana - **[Aktif]**
5. APC189D6X0276 - Dhia Nabila Rahma - **[Aktif]**

#### **A. Ringkasan Eksekutif**

Digitalisasi komunikasi telah mengubah cara komunitas akademik berinteraksi. Ruang obrolan digital kini menjadi medium utama pertukaran gagasan di lingkungan kampus, namun dibalik kemudahannya muncul permasalahan serius. Berbagai kasus pelecehan seksual verbal yang beredar di ruang digital membuktikan bahwa platform komunikasi masih rentan terhadap perilaku merusak. Pesan bermuatan ujaran kebencian menyebar sebelum siapa pun sempat bertindak, meninggalkan dampak psikologis pada korban dan mencoreng nama baik institusi.

Permasalahan intinya adalah tidak adanya mekanisme otomatis yang mampu mendeteksi konten tidak pantas secara real-time dalam percakapan berbahasa Indonesia. Moderasi manual bergantung pada reaksi manusia yang tidak konsisten sehingga banyak pesan berbahaya lolos sebelum sempat dihapus. Kami merumuskan tiga pertanyaan penelitian: seberapa akurat IndoBERT yang di-fine-tune dalam mengklasifikasikan pesan sebagai pantas atau tidak pantas, berapa confidence threshold yang optimal, dan apakah notifikasi edukatif dapat mendorong perubahan kebiasaan berbahasa pengirim menuju standar komunikasi akademik.

Untuk menjawab permasalahan tersebut, kami membangun AI SHIELD, sistem moderasi pesan berbasis kecerdasan buatan yang terintegrasi dalam simulasi forum chat berbasis web. Model IndoBERT di-fine-tune menggunakan dataset ujaran kebencian bahasa Indonesia untuk mengklasifikasikan pesan menjadi dua kategori:

pantas dan tidak pantas. Pesan yang terdeteksi tidak pantas langsung disembunyikan, dan pengirimnya menerima notifikasi edukatif yang mendorong mereka menyampaikan ulang gagasan dengan pilihan kata yang lebih baik.

Kami memilih proyek ini karena keamanan ruang komunikasi akademik adalah kebutuhan nyata yang belum terpenuhi. AI SHIELD bukan sekadar penyaring konten, melainkan alat edukasi untuk membangun kebiasaan berbahasa santun sejak dini, agar nilai kesantunan yang seharusnya menjadi ciri khas dunia akademik terwujud dalam komunikasi sehari-hari.

## **B. Cakupan Proyek dan Hasil Kerja**

Pada proyek ini, terdapat beberapa batasan proyek untuk memaksimalkan kebutuhan utama sistem. Pembatasan proyek ini terbagi menjadi 2 bagian, yaitu: In Scope (yang akan dikerjakan) dan Out of Scope (tidak dikerjakan). Rincian pembatasan proyek pada kedua bagian tersebut sebagai berikut:

- **In Scope:**
  - Fine-tuning model IndoBERT untuk klasifikasi teks biner (PANTAS / TIDAK PANTAS) dengan kebijakan zero-tolerance bahasa kasar.
  - Backend API (FastAPI) dengan endpoint moderasi dan WebSocket real-time.
  - Simulasi aplikasi chat web melalui React.js yang terintegrasi penuh dengan AI moderasi.
  - Dashboard admin untuk memantau log pelanggaran dan statistik moderasi.
  - Endpoint demo interaktif berbasis Streamlit sesuai syarat deliverable PIJAK.
- **Out of Scope:**
  - Integrasi langsung ke aplikasi WhatsApp asli (akses API resmi sangat terbatas).
  - Moderasi konten berupa gambar, audio, atau video (hanya teks).
  - Sistem autentikasi pengguna yang kompleks.
  - Deployment ke server produksi berbayar.

Dalam memecahkan kasus tersebut, setiap individu diberikan beberapa cakupan tugas melalui beberapa role yang dipilih oleh setiap anggota sebagai berikut:

| No | Peran              | Tanggung Jawab Utama                                                                                                                                                                         |
|----|--------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 1  | Project Manager    | Monitoring progress proyek, koordinasi tim internal dan tim eksternal PIJAK, testing end-to-end, dan memastikan beberapa dokumen yang dibutuhkan seperti PPT, video testing, dan sejenisnya. |
| 2  | AI/ML Engineer     | Pencarian dataset pendukung, pengolahan data, menyiapkan dan membuat model AI, evaluasi model, dan demo sistem.                                                                              |
| 3  | Backend Developer  | Pembuatan FastAPI, pengelolaan database, endpoint API, WebSocket, dan integrasi model.                                                                                                       |
| 4  | Frontend Developer | Pembuatan halaman sistem website dengan menggunakan framework JavaScript.                                                                                                                    |

Setelah dibuatkan beberapa tugas pada setiap role anggota, terbentuk suatu milestone proyek untuk memastikan bahwa proyek berada dalam batas waktu yang telah ditetapkan oleh PIJAK. Milestone proyek terdiri dari beberapa pekan di mana setiap pekan terdiri dari beberapa tugas dengan rincian sebagai berikut:

| No | Urutan Pekan | Tanggal        | Target Pencapaian                                                                                  |
|----|--------------|----------------|----------------------------------------------------------------------------------------------------|
| 1  | Weekly #1    | 11-17 Mei 2026 | Setup repo GitHub, environment dev, dataset terkumpul, EDA selesai, skeleton FastAPI & React jalan |
| 2  | Weekly #2    | 18-24 Mei 2026 | Fine-tuning IndoBERT iterasi pertama, endpoint API moderasi berfungsi, komponen                    |

|   |           |                |                                                                                                              |
|---|-----------|----------------|--------------------------------------------------------------------------------------------------------------|
|   |           |                | chat UI selesai                                                                                              |
| 3 | Weekly #3 | 25-31 Mei 2026 | Model dievaluasi & dioptimasi, WebSocket real-time berfungsi, Streamlit demo online, integrasi AI→BE selesai |
| 4 | Weekly #4 | 1-7 Juni 2026  | Integrasi penuh FE↔BE↔AI, dashboard admin berfungsi, laporan kemajuan PIJAK diisi (deadline 3 Jun)           |
| 5 | Weekly #5 | 8-19 Juni 2026 | Testing end-to-end, bug fixing, README lengkap, Project Brief, slide, rekam & upload video (deadline 19 Jun) |

### C. Jadwal Pengerjaan

### D. Uraian Rencana Penugasan/*Job Desk* Setiap Learning Path

Pada bagian ini, terdapat rincian tugas yang diberikan kepada setiap role anggota sebagai berikut:

- **Project Manager**

Role "Project Manager" ditugaskan untuk memastikan seluruh tim bergerak sesuai jadwal, mengkoordinasikan integrasi antar komponen, dan bertanggung jawab atas semua deliverable dokumen PIJAK.

| No | Task           | Deskripsi                                                                     |
|----|----------------|-------------------------------------------------------------------------------|
| 1  | Koordinasi Tim | Memimpin daily standup dan weekly sync, memantau progress via GitHub Projects |

|   |                     |                                                                                                         |
|---|---------------------|---------------------------------------------------------------------------------------------------------|
| 2 | Setup Github Repo   | Inisialisasi repo private, buat struktur folder, setup .gitignore, buat branch strategy                 |
| 3 | Integrasi & Testing | Memimpin fase integrasi FE↔BE↔AI, menulis test case end-to-end, koordinasi bug fixing                   |
| 4 | README              | Menulis dokumentasi instalasi, cara menjalankan, link model, referensi dataset                          |
| 5 | Project Brief       | Menyusun dokumen Project Brief sesuai template PIJAK berdasarkan hasil implementasi                     |
| 6 | Slide Presentasi    | Membuat slide yang mencakup latar belakang, solusi, demo, dan hasil evaluasi model                      |
| 7 | Video Presentasi    | Mengkoordinasikan rekaman video 10 menit, memastikan semua anggota hadir dan mempresentasikan bagiannya |
| 8 | Panduan Penggunaan  | Membuat panduan PDF atau video tutorial singkat cara menggunakan aplikasi                               |

- **Machine Learning / AI Engineer**

Role "Machine Learning / AI Engineer" ditugaskan menjadi penanggung jawab atas seluruh siklus pengembangan model, mulai dari pengumpulan data hingga model siap digunakan oleh backend.

| No | Task                            | Deskripsi                                                                                                              |
|----|---------------------------------|------------------------------------------------------------------------------------------------------------------------|
| 1  | Pengumpulan Dataset             | Mengumpulkan dataset hate speech & abusive language berbahasa Indonesia dari GitHub, Kaggle, dan sumber publik lainnya |
| 2  | EDA (Exploratory Data Analysis) | Menganalisis distribusi label, panjang teks, frekuensi kata, dan potensi bias pada dataset                             |

|    |                            |                                                                                                                                                                                     |
|----|----------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 3  | Preprocessing Teks         | Lowercasing, hapus URL/emoji/karakter khusus, normalisasi slang menggunakan kamus alay, tokenisasi                                                                                  |
| 4  | Split Dataset              | Membagi data menjadi train/validation/test (70/15/15) dengan stratified split                                                                                                       |
| 5  | Relabeling Dataset         | Mengonversi label multi-kelas dataset ke 2 kelas biner: PANTAS dan TIDAK PANTAS. Semua bentuk bahasa kasar, slang negatif, dan pelecehan digabung ke label TIDAK PANTAS             |
| 6  | Fine-tuning IndoBERT       | Melatih model indobert-base-p1 untuk binary classification menggunakan PyTorch + HuggingFace, dengan kebijakan zero-tolerance (termasuk bahasa gaul kasar meski konteksnya positif) |
| 7  | Evaluasi Model             | Menghitung Accuracy, Precision, Recall, F1-Score, plot Confusion Matrix, kalibrasi confidence threshold optimal (default 0.75)                                                      |
| 8  | Optimasi Model             | Tuning hyperparameter (learning rate, batch size, epoch), augmentasi data kelas TIDAK PANTAS jika $F1 < 82\%$                                                                       |
| 9  | Inference Function         | Membuat fungsi predict(text) → mengembalikan {label, confidence} yang dipanggil oleh backend                                                                                        |
| 10 | Streamlit Demo             | Membangun endpoint demo interaktif: input teks bebas → tampilkan label PANTAS/TIDAK PANTAS + confidence score + contoh notifikasi edukatif + visualisasi metrik model               |
| 11 | Simpan & Dokumentasi Model | Upload model ke Google Drive, cantumkan link di README, dokumentasikan cara mengunduh & memuat model                                                                                |

- **Backend Developer**

Role “Backend Developer” ditugaskan menjadi penanggung jawab atas pembangunan server API sebagai jembatan antara model AI, database, dan frontend.

| No | Task                                 | Deskripsi                                                                                                                                                                                                                                        |
|----|--------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 1  | Setup Project                        | Inisialisasi FastAPI, struktur folder, virtual environment, konfigurasi .env                                                                                                                                                                     |
| 2  | Desain Database                      | Merancang schema tabel: users, messages, rooms, violations menggunakan SQLAlchemy                                                                                                                                                                |
| 3  | Endpoint POST /api/messages          | Menerima pesan dari FE, memanggil AI inference, menyimpan hasil ke database, mengembalikan respons                                                                                                                                               |
| 4  | Integrasi AI                         | Memuat model IndoBERT ke memori saat server start, memanggil fungsi inference di setiap pesan masuk                                                                                                                                              |
| 5  | WebSocket /ws/{room_id}              | Mengelola koneksi real-time antar pengguna dalam satu room chat                                                                                                                                                                                  |
| 6  | Endpoint GET /api/messages/{room_id} | Mengambil riwayat pesan sebuah room (dengan pagination)                                                                                                                                                                                          |
| 7  | Logika Aksi Moderasi                 | Mengimplementasikan aturan biner: PANTAS → tampil normal; TIDAK PANTAS → sembunyikan pesan + kirim notifikasi edukatif ke pengirim + catat ke log pelanggaran. Confidence < 0.75 tetap disembunyikan namun pengirim dapat ajukan review ke admin |
| 8  | Endpoint Admin                       | GET /api/admin/violations (log pelanggaran) dan GET /api/admin/stats (statistik agregat)                                                                                                                                                         |
| 9  | Validasi & Keamanan                  | CORS setup, validasi input request, sanitasi teks sebelum dikirim ke model                                                                                                                                                                       |
| 10 | Testing & Dokumentasi                | Unit test endpoint utama, buat .env.example, dokumentasi API (FastAPI auto-docs)                                                                                                                                                                 |

- **Frontend Developer**

Role "Frontend Developer" ditugaskan menjadi penanggung jawab atas pembangunan antarmuka pengguna simulasi chat yang intuitif, responsif, dan terintegrasi penuh dengan backend.

| No | Task                | Deskripsi                                                                                                                                                                                                                   |
|----|---------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 1  | Setup Project       | Inisialisasi React (Vite) + Tailwind CSS, konfigurasi folder components, pages, services                                                                                                                                    |
| 2  | Komponen ChatBubble | Menampilkan pesan dengan 2 varian: tampil normal (PANTAS) atau tersembunyi dengan placeholder edukatif (TIDAK PANTAS)                                                                                                       |
| 3  | Komponen ChatInput  | Input teks dengan tombol kirim, validasi input tidak kosong                                                                                                                                                                 |
| 4  | Komponen ChatHeader | Header ruang chat (nama grup, jumlah anggota aktif)                                                                                                                                                                         |
| 5  | Halaman Login       | Form sederhana untuk memilih nama pengguna simulasi sebelum masuk ke room chat                                                                                                                                              |
| 6  | Halaman ChatRoom    | Menggabungkan semua komponen chat, mengelola state pesan, scroll otomatis ke pesan terbaru                                                                                                                                  |
| 7  | Integrasi WebSocket | Menghubungkan FE ke WebSocket BE untuk penerimaan pesan real-time                                                                                                                                                           |
| 8  | Notifikasi Moderasi | Pesan edukatif personal yang muncul hanya untuk pengirim saat pesannya disembunyikan: "Pesanmu disembunyikan karena tidak sesuai standar komunikasi akademik. Coba sampaikan kembali dengan pilihan kata yang lebih tepat." |
| 9  | Halaman RoomList    | Daftar room/grup yang tersedia untuk dipilih pengguna                                                                                                                                                                       |



|    |                           |                                                                                               |
|----|---------------------------|-----------------------------------------------------------------------------------------------|
| 10 | Halaman AdminDashboard    | Tabel log pelanggaran (nama pengguna, pesan, label, waktu) + grafik statistik (pie/bar chart) |
| 11 | Responsif Design          | Memastikan tampilan berfungsi baik di layar mobile ( $\geq 375\text{px}$ ) dan desktop        |
| 12 | Integrasi Penuh dengan BE | Menghubungkan semua komponen dengan endpoint API backend yang sudah selesai                   |

## E. Sumber Daya Proyek

- Bahasa Pemrograman**

| No | Bahasa      | Jenis Penggunaan          | Fungsi                                                                 |
|----|-------------|---------------------------|------------------------------------------------------------------------|
| 1  | Python 3.11 | Backend, AI/ML, Streamlit | Pengembangan model AI dan server backend. Ekosistem library ML lengkap |
| 2  | JavaScript  | Frontend (React)          | Pembangunan antarmuka pengguna yang interaktif                         |
| 3  | SQL         | Database                  | Query dan manajemen data pesan, pengguna, dan log pelanggaran          |

- Framework & Library**

| No | Framework/library | Layer   | Fungsi                                                                                                              |
|----|-------------------|---------|---------------------------------------------------------------------------------------------------------------------|
| 1  | FastAPI           | Backend | Framework Python modern untuk membangun REST API berkecepatan tinggi dengan dukungan async dan dokumentasi otomatis |
| 2  | SQLAlchemy        | Backend | ORM untuk manajemen                                                                                                 |

|   |                          |               |                                                                                                   |
|---|--------------------------|---------------|---------------------------------------------------------------------------------------------------|
|   |                          |               | database secara programatik tanpa menulis SQL mentah                                              |
| 3 | HuggingFace Transformers | AI/ML         | Menyediakan model IndoBERT pre-trained dan pipeline fine-tuning yang siap pakai                   |
| 4 | PyTorch                  | AI/ML         | Framework deep learning sebagai engine pelatihan model IndoBERT                                   |
| 5 | Scikit-learn             | AI/ML         | Digunakan untuk evaluasi model (classification report, confusion matrix, split dataset)           |
| 6 | React.js (Vite)          | Frontend      | Framework JavaScript untuk membangun antarmuka pengguna berbasis komponen yang cepat dan reaktif  |
| 7 | Tailwind CSS             | Frontend      | Framework CSS utility-first untuk desain antarmuka yang konsisten dan responsif                   |
| 8 | Streamlit                | Demo Endpoint | Membangun antarmuka demo interaktif model AI hanya dengan Python, sesuai syarat deliverable PIJAK |
| 9 | WebSockets (FastAPI)     | Backend       | Protokol komunikasi dua arah untuk fitur chat real-time tanpa perlu refresh halaman               |

- **Dataset**

| No | Dataset                                   | Sumber                                                                                                                                                                                            | Jumlah Data   | Fungsi                                                                                         |
|----|-------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|---------------|------------------------------------------------------------------------------------------------|
| 1  | Indonesian Hate Speech & Abusive Language | <a href="https://github.com/okkyibrohim/id-multi-label-hate-speech-and-abusive-language-detection/">https://github.com/okkyibrohim/id-multi-label-hate-speech-and-abusive-language-detection/</a> | ~13.000 tweet | Dataset utama; label multi-kelas dikonversi ke biner (PANTAS/TIDAK PANTAS) sebelum fine-tuning |

- **Tools Pengembangan & Kolaborasi**

| No | Task                          | Deskripsi                                                                      |
|----|-------------------------------|--------------------------------------------------------------------------------|
| 1  | Github (Private Repo)         | Version control, kolaborasi kode, tracking task via GitHub Projects            |
| 2  | Google Colab                  | Platform training model dengan GPU gratis (T4/P100) untuk fine-tuning IndoBERT |
| 3  | Google Drive                  | Penyimpanan file model AI (ukuran > 400MB, tidak bisa disimpan di GitHub)      |
| 4  | Streamlit Cloud               | Hosting gratis untuk deploy endpoint demo Streamlit agar dapat diakses publik  |
| 5  | Postman                       | Pengujian endpoint API backend secara manual selama development                |
| 6  | Google Meet + Google Calendar | Koordinasi meeting tim dan pengingat deadline PIJAK                            |
| 7  | Notion / GitHub Projects      | Manajemen task dan progress tracking harian                                    |

- **Referensi Ilmiah**

| No | Referensi                                                                          | Fungsi dalam Proyek                                 |
|----|------------------------------------------------------------------------------------|-----------------------------------------------------|
| 1  | Ibrohim & Budi (2019)<br>– Multi-label Hate Speech Detection in Indonesian Twitter | Dasar metodologi klasifikasi dan penggunaan dataset |
| 2  | Wilie et al. (2020) – IndoNLU: Benchmark for Indonesian NLU                        | Acuan benchmark performa model bahasa Indonesia     |
| 3  | Devlin et al. (2018) – BERT: Pre-training of Deep Bidirectional Transformers       | Landasan teori arsitektur model yang digunakan      |
| 4  | HuggingFace Docs – Fine-tuning a pretrained model                                  | Panduan teknis implementasi fine-tuning             |

## F. Rencana Manajemen Risiko dan Isu